

ТЕОРЕТИЧЕСКИЕ ОСНОВЫ ОТСЛЕЖИВАНИЯ ПАРТИТУРЫ В РЕАЛЬНОМ ВРЕМЕНИ: ОТ СКРЫТЫХ МАРКОВСКИХ МОДЕЛЕЙ И ON-LINE TIME WARPING К ОБУЧЕНИЮ С ПОДКРЕПЛЕНИЕМ

Н. А. Новицкий^{1,*}, Н. С. Борисов^{2,†}

¹АНО Центральный Университет, бывш. НИУ ВШЭ

²АНО Центральный Университет

Аннотация. Отслеживание партитуры в реальном времени — задача синхронизации живого исполнения с её символьной записью, лежащая в основе автоматического аккомпанемента, обучающих систем и виртуальных оркестров. В настоящей работе проводится систематическое теоретическое изложение моделей и алгоритмов, развитых в области с 1978 по 2026 год: от классического динамического программирования Сакоэ-Чибы [?] и каузальной модификации Диксона для On-line Time Warping [?], через скрытые марковские модели [? ?], гибридные модели с явной длительностью состояний [? ?], до современных нейросетевых подходов [? ?]. Отдельно подробно разбирается недавнее семейство методов на основе обучения с подкреплением, начиная с работы Дорфера и коллег [?] и до работ Петер [?] и Ву [?], и формулируется теоретическая постановка нового гибридного подхода, в котором RL-агент действует как тонкий слой опережающего предсказания темпа поверх вероятностного трекера, а не заменяет его целиком. Кроме того, обсуждаются перспективы переноса методов слотированного символьного марковского моделирования и distribution fields из астроинформатики в задачу отслеживания партитуры. Работа имеет теоретический характер: численные эксперименты не приводятся и обозначены как направления продолжения исследования.

Ключевые слова: отслеживание партитуры, скрытые марковские модели, скрытая полу-марковская модель, on-line time warping, обучение с подкреплением, опережающее предсказание темпа, PPO, GAE, distribution fields, multiview metric learning, виртуальный оркестр, аккомпанемент в реальном времени

ВВЕДЕНИЕ

Автоматический аккомпанемент относится к числу старейших и наиболее требовательных задач анализа музыкальной информации. Солист ожидает, что оркестр будет следовать за его темпом, динамикой и артикуляцией в реальном времени; для убедительной иллюзии живого ансамбля суммарная задержка между моментом звукоизвлечения солиста и соответствующим оркестровым событием не должна превышать 20 мс — порог восприятия рассинхронизации в музыкальном ансамбле [? ?]. Технически эта задача формулируется как *отслеживание партитуры в реальном времени (score following)* [?]: по поступающему каузально потоку наблюдений (MIDI-событий или аудиосигнала) и заранее известной символьной партитуре требуется оценивать текущую позицию исполнителя и при необходимости управлять воспроизведением сопровождения.

Развитие области охватывает более четырёх десятилетий и прошло через несколько принципиальных этапов. Первоначально — работы Данненберга [?] и Веркоу [?], независимо опубликованные в 1984 году, — задача решалась средствами динамического программирования, перенесёнными из области распознавания речи [?]. На рубеже двухтысячных доминирующей рамкой стало вероятностное моделирование с исполь-

зованием скрытых марковских моделей [?], позволившее естественно описывать неопределённость в текущей позиции и ошибки исполнителя [? ? ? ?]. С 2018 года интенсивно развиваются нейросетевые и глубокие подходы, обучаемые непосредственно на больших корпусах выровненных аудиозаписей [? ? ?]. Параллельно появилось отдельное направление, формализующее отслеживание партитуры как задачу обучения с подкреплением [? ? ? ?], и обзорная работа [?] систематизирует возникшее многообразие живых музыкальных агентов.

Настоящая работа имеет *теоретический и обзорный характер*. Её цели сводятся к четырём пунктам: во-первых, дать единое математическое изложение основных моделей и алгоритмов отслеживания партитуры — от Dynamic Time Warping и On-line Time Warping до полу-марковских моделей с явной длительностью [?] и НММ-моделей с обработкой ошибок [?]; во-вторых, систематически рассмотреть фундаментальные методы обучения с подкреплением, релевантные для нашей задачи (PPO, GAE, обучение по предпочтениям [? ? ?]), и провести подробный обзор всех известных авторам работ, применяющих обучение с подкреплением непосредственно к задаче музыкального аккомпанемента или отслеживания партитуры [? ? ? ? ?]; в-третьих, сформулировать теоретическую постановку нового гибридного подхода, в котором RL-агент действует как *тонкий слой опережающего предсказания темпа* поверх классического вероятностного трекера, а не заменяет его целиком, и обсудить, чем такая постановка отличается от суще-

* n.novitskiy@edu.centraluniversity.ru

† n.borisov@edu.centraluniversity.ru

ствующих RL-подходов; в-четвёртых, обсудить перспективы переноса в задачу отслеживания партитуры методов *slotted symbolic Markov modeling and distribution fields*, оригинально развитых в астроинформатике для классификации временных рядов переменных звёзд [? ? ?].

Работа сознательно не содержит численных экспериментов: цель статьи — дать математически выверенный, полный и прослеживаемый по литературе теоретический фундамент, на который можно опираться при последующем практическом внедрении. Все обсуждаемые количественные характеристики (точность выравнивания, задержка, F1-мера onset-событий) приводятся с прямой ссылкой на источник и описывают результаты оригинальных авторов, а не настоящей работы.

Структура изложения соответствует перечисленным целям. В разд. II проводится обзор существующих работ, разбитый на четыре тематических блока: классические DP-следователи, НММ-модели, современные нейросетевые подходы и обучение с подкреплением для музыки. В разд. III формализуется задача отслеживания партитуры. В разд. IV последовательно излагается математический аппарат: DTW и его on-line модификация, базовая НММ Рабинера [?], полу-марковские модели и гибридная архитектура Конта [?], а также два метода-кандидата на перенос из астроинформатики — SSMM и *distribution fields*. В разд. VI приводится фундамент обучения с подкреплением в объёме, необходимом для понимания современных методов: марковские процессы принятия решений, оценка преимуществ, алгоритм PPO, обучение по предпочтениям. В разд. VII детально разбираются известные нам работы, применяющие RL к музыкальному аккомпанементу или отслеживанию партитуры; для каждой указывается постановка MDP, архитектура агента, функция вознаграждения и характер новизны. В разд. VIII формулируется теоретическая постановка нашей гибридной схемы. В разд. IX обсуждаются открытые вопросы и ограничения, в разд. X — итоги и направления дальнейшей работы. Полные псевдокоды Forward, Viterbi, Forward для гибридной полу-марковской модели и схема обучения PPO вынесены в Приложения А–Г.

ОБЗОР СУЩЕСТВУЮЩИХ РАБОТ

Существующие работы по отслеживанию партитуры удобно сгруппировать в четыре тематических направления, отражающих историческую последовательность развития области и одновременно различающихся по типу применяемого математического аппарата. Ниже последовательно рассматриваются: классические алгоритмы динамического программирования и их каузальные модификации; вероятностные модели на основе скрытых марковских процессов и их полу-марковских расширений; современные нейросетевые подходы; и относительно недавно сформировавшееся семейство методов, в которых отслеживание партитуры формулируется как задача обучения с под-

креплением.

Классические алгоритмы динамического программирования. Современные методы выравнивания временных рядов берут начало с работы Сакоэ и Чибы [?], в которой для задачи распознавания речи введён алгоритм Dynamic Time Warping и его теперь стандартная полоса ограничений. Перенос идей в задачу отслеживания партитуры независимо предложен Данненбергом и Веркоу [? ?]: оба автора рассматривают исполнение и партитуру как два потока однотипных событий и сопоставляют их по принципу динамического программирования с допуском ошибок. Существенным каузальным расширением является On-line Time Warping Диксона [?], в котором матрица накопленных стоимостей заполняется столбец за столбцом по мере поступления новых наблюдений, а специальный счётчик *RunCount* ограничивает число последовательных шагов в одном направлении и тем самым предотвращает «застревание» алгоритма. Подробное изложение DTW и музыкальных применений приведено в монографии Мюллера [?] и более поздней учебной книге [?], а в диссертации Арцта [?] систематизирован опыт построения надёжных DP-следователей под концертные условия.

Вероятностные модели на основе скрытых марковских процессов. Учебная статья Рабинера [?] остаётся канонической ссылкой для алгоритмов Forward, Backward, Viterbi и переоценки параметров методом Баума–Уэлча; именно эта нотация используется во всём дальнейшем изложении. Применение НММ к задаче отслеживания партитуры впервые систематически проведено в работе Орио и Дешелля [?]: предложена двухуровневая модель, в которой нижний уровень моделирует ноты как фазы *attack–sustain–silence*, а верхний — допустимые ошибки исполнителя через параллельные «теневые» состояния. Конт с соавторами [?] развил эту линию до иерархической НММ с разреженными неотрицательными ограничениями для полифонического выравнивания. Ключевым теоретическим достижением оказалась работа Конта [?], в которой предложена *гибридная* архитектура из двух связанных вероятностных агентов — аудио-агента и темпо-агента — работающих в одной байесовской инференц-схеме; при этом темпоральные элементы партитуры моделируются как полу-марковский процесс с явным распределением длительностей $d_j(u)$, а атемпоральные (орнаменты, трели) — как обычный марковский процесс с геометрической длительностью. Эта архитектура положена в основу системы Antescofo, активно используемой в концертной практике IRCAM с 2007 года. Параллельно Рафаэль [?] развивал родственный, но самостоятельный подход — переключающиеся пространства состояний с явным гауссовским тайминг-моделем для пары (t_n, s_n) , объединённой с НММ-наблюдательной частью; в системе Music Plus One этот подход позволяет адаптироваться к конкрет-

ному солисту от репетиции к репетиции через off-line ЕМ. Накамура с соавторами [?] рассмотрели задачу в наиболее общей постановке — с произвольными повторами, пропусками и фальшивыми нотами — и предложили факторизацию переходного графа, понижающую сложность шага Forward с $O(N^2)$ до $O(N)$.

Современные нейросетевые подходы. С 2018 года активно развивается семейство методов, обучаемых сквозным образом на больших корпусах выровненных аудиозаписей. Хоторн с соавторами [?] в работе Onsets and Frames ввели двойную целевую функцию — покadroвое присутствие ноты плюс отдельную голову для onset-событий; их же работа 2019 года [?] ввела датасет MAESTRO объёмом 172.3 ч с точностью выравнивания около 3 мс, который стал стандартным бенчмарком для пианистической транскрипции. Арцт и Латтнер [?] предложили обучаемые транспозиционно-инвариантные признаки на основе gated-autoencoder'a, превратив задачу audio-to-score в задачу audio-to-audio выравнивания после синтеза партитуры через семплер. Хенкель и Видмер [?] разработали систему Conditional YOLO с условием FiLM-параметров от аудио, ведущую следование непосредственно по *изображению* партитуры на трёх разрешениях (нота, такт, система); такая постановка снимает зависимость от дорогой нотно-уровневой разметки. Аграваль и Диксон [?] рассмотрели гибридную схему, в которой обученный сиамской CNN признак заменяет ручную chroma в матрице сходства, а само выравнивание по-прежнему ведётся методом DTW.

Обучение с подкреплением для отслеживания партитуры и аккомпанемента. Принципиально иная постановка предложена Дорфером и коллегами [?]: задача формулируется как мультимодальный марковский процесс принятия решений, в котором состояние объединяет окно изображения партитуры с участком спектрограммы, а действие изменяет скорость продвижения курсора по партитуре с шагом Δv_{pxl} . Обучение ведётся методом advantage actor-critic с шестнадцатью параллельными акторами и плотной линейной функцией вознаграждения $r = 1 - |d_x|/b$ внутри окна допустимых отклонений. Петер [?] предложил вариант для символьного выравнивания с офлайн-обучением через offline RL: трансформер аппроксимирует Q-функцию, но с дисконтом $\gamma = 0$ (полностью близорукий агент), благодаря чему задача сводится к бинарной классификации правильности выбранного onset-кандидата. Его система достигает медианной асинхронности 15.7 мс (против 60.6 мс у OLTW), что является лучшей известной авторам цифрой для онлайн-выравнивания символьного входа. Цзян с соавторами [?] в системе RL-Duet применили актор-критик с обобщённой оценкой преимуществ [?] к задаче генерации гармонического сопровождения для монофонической мелодии; функция вознаграждения собирается из ансамбля четырёх специализированных нейросетевых критиков. Ву с соавторами [?] в работе RealChords развили эту

линию через KL-контроль к офлайновому учителю, видящему всю мелодию целиком; такой подход формально решает проблему *exposure bias* при онлайн-генерации. Жак с соавторами [?] ранее предложили KL-контроль как общий приём дообучения предобученной MLE-модели последовательности с эвристическим внешним вознаграждением. Обзорная работа Кима с соавторами [?] систематизирует 184 систему живых музыкальных агентов в четырёх измерениях (Usage Context, Interaction, Technology, Ecosystem) с 31 детальной осью.

Перенос методов из астроинформатики. Отдельным направлением, ранее не представленным в литературе по MIR, являются методы slotted symbolic Markov modeling (SSMM) [?] и distribution fields [?], изначально развитые для классификации переменных звёзд по нерегулярным фотометрическим рядам [?]. Перенос этих методов в задачу отслеживания партитуры обсуждается в разд. V.

Положение настоящей работы. В отличие от работ [? ?], в которых RL-агент *заменяет* классический трекер целиком, и работ [? ?], в которых RL применяется к генерации музыки, а не к её отслеживанию, в разд. VIII обсуждается теоретическая возможность построения гибридной схемы: классический вероятностный трекер сохраняется как ядро, а RL-агент действует как *тонкий слой опережающего предсказания темпа* с целью компенсации задержек воспроизводящей части системы. Такая постановка не противоречит результатам указанных работ и формально дополняет их.

ФОРМАЛЬНАЯ ПОСТАНОВКА ЗАДАЧИ

Прежде чем перейти к рассмотрению алгоритмов, договоримся об обозначениях. Поскольку математический аппарат отслеживания партитуры заимствован из четырёх соседних областей — теории вероятностей, обработки сигналов, оптимального выравнивания и обучения с подкреплением, — в литературе по нему используется весьма пёстрый набор греческих и латинских букв. Чтобы избежать путаницы при чтении, мы заранее перечисляем все ключевые обозначения, по возможности повторяющие нотацию первоисточников.

Список основных обозначений. Партитура и исполнение. S — партитура (нотный текст), N — число нот в ней; i нумерует ноту партитуры от 1 до N . P — исполнение (живая запись), M — число наблюдаемых событий (заранее неизвестно); j нумерует событие исполнения. p_i — высота i -й ноты партитуры в стандарте MIDI, q_j — высота j -го события исполнения. Моменты времени: t_i — номинальный (по партитуре), τ_j — реальный (по исполнению). v_0 — номинальный темп партитуры (beat/секунду); $\hat{v}(t)$ — текущая оценка темпа исполнения. *Функция выравнивания.* Греческая ϕ (читается «фи») традиционно обозначает функцию выравнивания между исполнением и партитурой [? ?]; $\phi(j)$ — истинная позиция исполнителя на момент j -го события, $\hat{\phi}(j)$ — её оценка

(с «крышкой» по стандартной статистической традиции). *Скрытая марковская модель* (по Рабинеру [?]): $\lambda = (A, B, \pi)$, где $A = (A_{ij})$ — матрица переходов между состояниями, $B = \{b_i(o)\}$ — эмиссионные распределения, $\pi = (\pi_i)$ — начальное распределение по состояниям. $\alpha_i(j)$ — прямая (forward) переменная алгоритма, $\beta_i(j)$ — обратная (backward) переменная (не путать с темпом, для которого мы используем v); $\delta_i(j)$, $\psi_i(j)$ — переменные Viterbi-алгоритма; $d_j(u)$ — распределение длительности состояния в полу-марковской модели [?]. *Обучение с подкреплением*: $\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{T}, r, \gamma)$ — марковский процесс принятия решений; $s_t \in \mathcal{S}$ — состояние, $a_t \in \mathcal{A}$ — действие, r_t — мгновенное вознаграждение, $\gamma \in [0, 1]$ — дисконт-фактор; $\pi_\theta(a | s)$ — параметризованная политика (не путать с начальным распределением НММ).

С этой нотацией формализация задачи ниже остаётся короткой.

Партитура. Партитура задаётся последовательностью $S = \{(p_i, t_i^{\text{on}}, t_i^{\text{off}})\}_{i=1}^N$ из N нот, в которой $p_i \in \{0, \dots, 127\}$ — высота в стандарте MIDI, а $t_i^{\text{on}}, t_i^{\text{off}}$ — номинальные моменты начала и конца звучания относительно базового темпа v_0 (как правило, в beat-единицах). Исполнение поступает каузально как поток $P = \{(q_j, \tau_j^{\text{on}}, \tau_j^{\text{off}})\}_{j=1}^M$ с реализованными высотами q_j и реальными моментами времени τ_j .

Задача. Задача отслеживания партитуры состоит в построении каузального отображения

$$\varphi: \{1, \dots, M\} \longrightarrow \{1, \dots, N\}, \quad j \mapsto \varphi(j), \quad (1)$$

ставящего в соответствие каждому событию исполнения с номером j позицию $\varphi(j)$ в партитуре, причём оценка $\hat{\varphi}(j)$ вычисляется по информации только из прошлого: $q_1, \tau_1, \dots, q_j, \tau_j$. Поскольку в большинстве музыкальных контекстов исполнитель движется по партитуре вперёд — с возможными редкими пропусками, повторами и ошибками [?], но без систематического возврата назад — отображение φ обычно требуют удовлетворяющим условию монотонности

$$j_1 < j_2 \implies \varphi(j_1) \leq \varphi(j_2). \quad (2)$$

Для практического применения функция выравнивания дополняется оценкой текущего темпа исполнения $\hat{v}(t) > 0$, выражающей скорость движения исполнителя по партитуре в beat/секунду. Темп используется блоком воспроизведения сопровождения для синхронного синтеза оркестровой партии. В наиболее общей постановке [? ?] обе величины оцениваются совместно, а не последовательно: апостериорное распределение по позиции зависит от текущей оценки темпа, а оценка темпа — от истории согласованных событий.

Дополнительные требования. *Каузальность*: оценка $\hat{\varphi}(j)$ должна быть доступна не позже момента $\tau_j + L$, где L — допустимая задержка системы. *Робастность*: ошибки исполнителя (пропуски нот, фальшивые ноты, орнаменты), не предусмотренные партитурой, не должны приводить к потере синхронизации. *Адаптивность*: оценка темпа должна

реагировать на выразительные изменения исполнителя — ритарданто, ачелерандо, rubato — не теряя устойчивости.

МАТЕМАТИЧЕСКИЕ ОСНОВЫ МОДЕЛЕЙ ОТСЛЕЖИВАНИЯ ПАРТИТУРЫ

Математический аппарат отслеживания партитуры удобно строить от простого к сложному: первый кирпич — классический алгоритм Dynamic Time Warping, второй — его каузальная модификация On-line Time Warping, третий — скрытые марковские модели в формулировке Рабинера [?] и их прикладная адаптация для отслеживания партитуры, четвёртый — полу-марковские расширения с явной длительностью состояний и гибридная архитектура Конта [?]. Все обозначения соответствуют принятой в литературе нотации [? ? ?], и для самостоятельности изложения каждая модель выводится из предшествующей. Отдельно (см. разд. V) обсуждаются два метода — slotted symbolic Markov modeling и distribution fields, — оригинально развитые в смежной области астроинформатики и потенциально применимые в нашей задаче.

Запись партитуры на нотном стане. Прежде чем формализовать математику, полезно зафиксировать сам объект изучения. Партитура — это упорядоченная последовательность нот; каждой ноте соответствует пара (высота, длительность). В дальнейшем для сквозного учебного примера используем мажорное арпеджио из пяти нот: $S_{\text{ex}} = (C4, E4, G4, A4, C5)$, с MIDI-кодами (60, 64, 67, 69, 72) соответственно. Этот пример выбран минимальным: пять нот достаточно, чтобы проиллюстрировать все рекуррентные формулы, и одновременно короток для пошагового численного разбора.




РИС. 1. Сквозной учебный пример: пять нот (C4, E4, G4, A4, C5) на нотном стане в скрипичном ключе. На все последующие алгоритмы DTW, НММ и Forward будут применяться именно к этому фрагменту.

Dynamic Time Warping. Прежде всего поясним, для чего нужна эта конструкция. Допустим, у нас есть две последовательности признаков, описывающих одно и то же музыкальное событие, но идущих с разной скоростью: например, эталонная синтезированная по партитуре аудиодорожка $A = (a_1, \dots, a_I)$ длины I кадров и реальная запись исполнения $B = (b_1, \dots, b_J)$ длины J кадров (как правило $J \neq I$, потому что исполнитель играет с собственным темпом). Задача — найти такое нелинейное соответствие между кадрами A и B , при котором соотнесённые между собой кадры были максимально похожи по своему содержанию.

Формально соответствие задаётся *путём выравнивания* — последовательностью пар индексов $F = c(1), c(2), \dots, c(K)$, где $c(k) = (i(k), j(k))$ означает « $i(k)$ -й кадр A сопоставлен с $j(k)$ -м кадром B на k -м шаге пути». Допустимый путь обязан стартовать в левом нижнем углу матрицы индексов и заканчиваться в правом верхнем ($c(1) = (1, 1)$, $c(K) = (I, J)$); ходить по этой матрице можно только вправо, вверх или по диагонали (ровно на одну клетку), что и обеспечивает условия монотонности $i(k-1) \leq i(k)$, $j(k-1) \leq j(k)$ и непрерывность шага.

«Похожесть» двух кадров измеряется *локальной стоимостью* $d(i, j) = \|a_i - b_j\|$ (например, евклидовым расстоянием между chroma-векторами); чем меньше $d(i, j)$, тем больше сходство. Сложив локальные стоимости вдоль всего пути с весами $w(k)$, получаем суммарную стоимость $E(F) = \sum_{k=1}^K d(c(k))w(k)$. Веса $w(k) \geq 0$ нужны, чтобы все три типа шага (вправо, вверх, по диагонали) давали соразмерный вклад: например, в симметричной форме Сакоэ-Чибы [?, урavn. 12] диагональный шаг получает вес 2, а горизонтальный и вертикальный — по 1 (подробное обсуждение разных весовых схем — в [?, § II-B]).

Теперь содержательный вопрос: что значит «оптимальное» выравнивание двух последовательностей? Если бы мы просто брали путь с минимальной суммой $E(F)$, выгоднее всего было бы двигаться кратчайшим путём (короткий путь даёт меньшее число слагаемых даже при больших d). Чтобы устранить это смещение, Сакоэ и Чиба нормируют сумму на сумму весов и определяют *нормализованное расстояние* как минимум по всем допустимым путям:

$$D(A, B) = \min_F \frac{\sum_{k=1}^K d(c(k))w(k)}{\sum_{k=1}^K w(k)}. \quad (3)$$

Знаменатель $\sum_k w(k) = N$ — это, по сути, длина пути в весовом смысле; для симметричной формы $N = I + J$, для асимметричной $N = I$ [?, урavn. 13–15]. Деление на N делает $D(A, B)$ среднестрочной локальной стоимостью на пути и убирает преимущество коротких путей.

Геометрически минимум в (3) соответствует поиску *ломаной из нижнего левого угла в верхний правый* в прямоугольной матрице $I \times J$, на каждой ячейке которой лежит число $d(i, j)$, и эта ломаная должна давать минимальную сумму чисел вдоль себя (с учётом весов). Прямой перебор всех возможных путей экспоненциален по длине K , но существует элегантный приём — *динамическое программирование*: каждая частичная стоимость $g(i, j)$ на ячейке (i, j) зависит только от трёх соседних ячеек снизу и слева, и поэтому матрицу g можно заполнить за время $O(IJ)$. Для практической реализации применяется рекурсивная DP-формулировка [?, урavn. 16–18]: $g_1(c(1)) = d(c(1))w(1)$,

$$g_k(c(k)) = \min_{c(k-1)} [g_{k-1}(c(k-1)) + d(c(k))w(k)], \quad (4)$$

$D(A, B) = g_K(c(K))/N$, где $N = \sum_k w(k)$. Для симметричных весов $w(k) = (i(k) - i(k-1)) + (j(k) - j(k-1))$ и нулевого ограничения наклона рекурсия принимает компактный вид

$$g(i, j) = \min \begin{cases} g(i-1, j-1) + 2d(i, j), \\ g(i-1, j) + d(i, j), \\ g(i, j-1) + d(i, j), \end{cases} \quad (5)$$

с инициализацией $g(1, 1) = 2d(1, 1)$ и итоговым $D(A, B) = g(I, J)/(I + J)$. Для уменьшения вычислительной сложности с $O(NM)$ до $O(NR)$ применяется *полоса Сакоэ-Чибы* $|i(k) - j(k)| \leq R$ [?, урavn. 8].

В контексте отслеживания партитуры [? ?] последовательность A обычно соответствует синтезированной по партитуре аудиодорожке (или последовательности нот), B — живому исполнению; локальная стоимость $d(i, j)$ строится по chroma-векторам, спектральным признакам или, как в современной работе [?], по обучаемым транспозиционно-инвариантным эмбедингам.

Пример заполнения матрицы DTW. Пусть партитура — наш сквозной пример $S_{\text{ex}} = (60, 64, 67, 69, 72)$, а исполнение содержит шесть событий с реализованными высотами $P_{\text{ex}} = (60, 64, 67, 67, 69, 72)$ (третья нота сыграна дважды — типичная исполнительская «зацепка»). В качестве локальной стоимости используем $d(i, j) = |\text{midi}(s_i) - q_j|$ в полутонах. Прямой расчёт матрицы $g(i, j)$ по урavn. (5) даёт нижеследующую таблицу (показаны только значения внутри полосы Сакоэ-Чибы $|i - j| \leq 2$, остальные ячейки помечены прочерком):

$i \backslash j$	1	2	3	4	5	6
1 (C4=60)	0	4	—	—	—	—
2 (E4=64)	4	0	3	—	—	—
3 (G4=67)	—	3	0	0	2	—
4 (A4=69)	—	—	2	2	0	3
5 (C5=72)	—	—	—	5	3	0

Жирным показан оптимальный путь $W = (1, 1) \rightarrow (2, 2) \rightarrow (3, 3) \rightarrow (3, 4) \rightarrow (4, 5) \rightarrow (5, 6)$, соответствующий выравниванию: первая нота партитуры $\rightarrow$ первая исполнения, вторая $\rightarrow$ вторая, третья нота партитуры покрывает два последовательных наблюдения исполнения (это и есть «зацепка»), затем выравнивание продолжается стандартно. Итоговая нормированная стоимость пути — 0, поскольку все совпадения точные.

Геометрически путь визуализируется как ломаная в матрице накопленных стоимостей; пример более общей картины приведён на РИС. 2.




РИС. 2. Матрица накопленных стоимостей DTW для пяти нотного фрагмента (схематическая иллюстрация). Серым выделена полоса Сакоэ-Чиби при $R = 2$, чёрной ломаной — оптимальный путь выравнивания.

On-line Time Warping. Каузальная модификация DTW предложена Диксоном [?] для случая, когда последовательность B поступает потоково и заранее не известна. Алгоритм поддерживает две позиции — текущую строку i_{cur} и текущий столбец j_{cur} — и при поступлении новой ноты q_j обновляет столбец матрицы D в окне $[i_{\text{cur}} - W, i_{\text{cur}} + W]$ согласно стандартной DP-рекурсии уравн. (5). Выбор следующей ячейки определяется минимизацией нормализованной частичной стоимости среди трёх возможных направлений (увеличить строку, столбец или оба индекса одновременно). Особенностью алгоритма является счётчик *RunCount*: если выбор направления повторяется более R_{max} раз подряд, обработка принудительно переключается на ортогональное направление, что предотвращает застревание на одной строке партитуры в случае акустически неоднозначных моментов. Параметр R_{max} типично выбирается равным 3 [?]; ширина окна W задаётся как $\lceil \alpha N \rceil$ с $\alpha \approx 0.1$.

Скрытая марковская модель. Скрытая марковская модель [?] с конечным числом состояний $\mathcal{S} = \{S_1, \dots, S_N\}$ и наблюдениями $O = (o_1, \dots, o_T)$ полностью характеризуется тройкой $\lambda = (A, B, \pi)$, где $A = (A_{ij})$ — матрица переходов $A_{ij} = \mathbb{P}(q_{t+1} = S_j | q_t = S_i)$, B — эмиссионные распределения $b_i(o) = \mathbb{P}(o | q_t = S_i)$, $\pi = (\pi_i)$ — начальное распределение $\pi_i = \mathbb{P}(q_1 = S_i)$. Стохастические ограничения требуют $\sum_j A_{ij} = 1$, $\sum_o b_i(o) = 1$ и $\sum_i \pi_i = 1$.

В формулировке Рабинера [?, стр. 261] перед исследователем стоят три фундаментальные задачи: *задача оценивания* — вычислить $\mathbb{P}(O | \lambda)$ для заданной последовательности наблюдений и параметров; *задача декодирования* — найти наиболее вероятную последовательность скрытых состояний $\hat{Q}^* = \arg \max_Q \mathbb{P}(Q | O, \lambda)$; *задача обучения* — подобрать параметры λ , максимизирующие правдоподобие наблюдений.

Ключевым инструментом для решения первых двух задач является *прямая (forward) переменная*, определённая как [?, уравн. 18]

$$\alpha_i(i) = \mathbb{P}(o_1, \dots, o_i, q_i = S_i | \lambda). \quad (6)$$

Прямая рекурсия [?, уравн. 19–20] имеет вид

$$\alpha_1(i) = \pi_i b_i(o_1), \quad \alpha_{t+1}(j) = \left[\sum_{i=1}^N \alpha_t(i) A_{ij} \right] b_j(o_{t+1}), \quad (7)$$

а полная вероятность наблюдений [?, уравн. 21]

$$\mathbb{P}(O | \lambda) = \sum_{i=1}^N \alpha_T(i). \quad (8)$$

Симметрично определяется *обратная переменная* $\beta_i(i) = \mathbb{P}(o_{t+1}, \dots, o_T | q_t = S_i, \lambda)$ с рекурсией $\beta_T(i) = 1$ и

$$\beta_t(i) = \sum_{j=1}^N A_{ij} b_j(o_{t+1}) \beta_{t+1}(j). \quad (9)$$

Вычислительная сложность каждой рекурсии — $O(N^2 T)$ против $O(T \cdot N^T)$ для прямого перебора [?, стр. 262]. Для онлайн-применения существенно, что $\mathbb{P}(q_t = S_i | o_1, \dots, o_t) \propto \alpha_t(i)$: после покadroвой нормировки $\tilde{\alpha}_t(i) = \alpha_t(i) / \sum_k \alpha_t(k)$ получаем апостериорное распределение, по которому удобно получать каузальную оценку позиции: $\hat{\phi}(t) = \arg \max_i \tilde{\alpha}_t(i)$. Эта же нормировка устраняет численное переполнение для длинных последовательностей [?, §V-A].

Алгоритм Витерби. Решение задачи декодирования по критерию максимальной вероятности пути даёт алгоритм Витерби. Вводятся переменные $\delta_t(j) = \max_{q_1, \dots, q_{t-1}} \mathbb{P}(q_1, \dots, q_t = S_j, o_1, \dots, o_t | \lambda)$ и обратные указатели $\psi_t(j)$ [?, уравн. 32–35]:

$$\delta_t(j) = b_j(o_t) \max_i [\delta_{t-1}(i) A_{ij}], \quad (10)$$

$$\psi_t(j) = \arg \max_i [\delta_{t-1}(i) A_{ij}], \quad (11)$$

с инициализацией $\delta_1(j) = \pi_j b_j(o_1)$, $\psi_1(j) = 0$. Оптимальная траектория восстанавливается обратным проходом: $q_T^* = \arg \max_j \delta_T(j)$, $q_{t-1}^* = \psi_t(q_t^*)$. Полный псевдокод вынесен в разд. XII.

НММ для отслеживания партитуры. Адаптация скрытой марковской модели к задаче отслеживания партитуры обладает специфической структурой, изначально предложенной Орио и Дешеллем [?] и развитой в последующих работах [???]. Состояния S_i ставятся в соответствие нотам партитуры, а матрица переходов имеет полосную структуру:

$$A_{ij} = \begin{cases} p_{\text{stay}}, & j = i, \\ p_{\text{advance}}, & j = i + 1, \\ p_{\text{skip}}, & j = i + 2, \\ 0, & \text{иначе}, \end{cases} \quad (12)$$

с условием нормировки $p_{\text{stay}} + p_{\text{advance}} + p_{\text{skip}} = 1$. Самозамыкание p_{stay} описывает ферматы и удлинённые ноты, переход $i \rightarrow i + 2$ — редкий пропуск ноты исполнителем [?]. В более полной модели Накамуры с соавторами [?] к указанным переходам добавляются переход $i \rightarrow i + 2$ как deletion, самозамыкание на верхнем

уровне как insertion, а также специальные «силент-перерывы» для обработки повторов произвольной длины. Эмиссионные распределения $b_i(o)$ зависят от выбора входного канала. Для MIDI-входа стандартной является гауссова форма $b_i(o) = \mathcal{N}(o; p_i, \sigma^2)$ с центром в высоте p_i и параметром σ , отражающим частоту октавных и полутоновых ошибок. Для аудиовхода Орио и Дешелль [?] использовали отношения энергий в первых гармониках ожидаемой ноты к полной энергии кадра, а в современных работах [? ? ?] эмиссионная плотность параметризуется свёрточной нейронной сетью. Конт [?] использует расхождение Кульбака-Лейблера между нормированным спектром кадра X_t и гармоническим шаблоном S_i :

$$D(S_i \| X_t) = \sum_f S_i(f) \log \frac{S_i(f)}{X_t(f)}, \quad b_i(o_t) \propto \exp[-\theta D(S_i \| X_t)], \quad (13)$$

с обучаемым параметром θ [?, урavn. 5–6].

Связь полосной матрицы (12) с конкретной партитурой удобнее всего показать диаграммой состояний; для нашего сквозного примера она приведена на РИС. 3.




РИС. 3. Диаграмма пятисостояний HMM для партитурного фрагмента $S_{ex} = (C4, E4, G4, A4, C5)$ при типичных значениях $p_{stay} = 0,3$, $p_{advance} = 0,6$, $p_{skip} = 0,1$; снизу — наблюдаемые события o_t , штриховые серые стрелки — эмиссии $b_i(o_t)$.

Численный пример Forward-рекурсии. Покажем, как работает урavn. (7) на минимальном примере. Возьмём партитуру S_{ex} , гауссову эмиссию для MIDI с $\sigma = 0,5$ полутона и полосную матрицу переходов с $p_{stay} = 0,3$, $p_{advance} = 0,6$, $p_{skip} = 0,1$. Начальное распределение $\pi = (1, 0, 0, 0, 0)$ — исполнитель начинает с первой ноты.

Пусть исполнение начинается с трёх событий: $o_1 = 60$ (точно C4), $o_2 = 64$ (точно E4), $o_3 = 63$ (полутонем ниже E4, лёгкая ошибка).

Эмиссии $b_i(o_t) \propto \exp(-(p_i - o_t)^2 / (2\sigma^2))$ дают для трёх временных шагов следующие (нормированные по строке) значения вероятностей:

o_t	b_1	b_2	b_3	b_4	b_5
$o_1 = 60$	1.000	0.000	0.000	0.000	0.000
$o_2 = 64$	0.000	1.000	0.000	0.000	0.000
$o_3 = 63$	0.000	0.135	0.000	0.000	0.000

(значения округлены до трёх знаков; экспоненциальное затухание $\exp(-2) \approx 0,135$ при разнице в две полутоновых σ). Применяя (7), последовательно полу-

чаем нормированные апостериоры:

$$\begin{aligned} \tilde{\alpha}_1 &= (1,000, 0,000, 0,000, 0,000, 0,000), \\ \tilde{\alpha}_2 &= (0,000, 1,000, 0,000, 0,000, 0,000), \\ \tilde{\alpha}_3 &= (0,000, 1,000, 0,000, 0,000, 0,000). \end{aligned}$$

То есть после трёх наблюдений модель уверенно (с вероятностью 1,000) полагает, что исполнитель находится во втором состоянии E4: третий звук $o_3 = 63$ ближе к E4=64, чем к G4=67, и эмиссия фиксирует state 2. Каузальная оценка позиции $\hat{\phi}(t) = \arg\max_i \tilde{\alpha}_t(i)$ выдаёт последовательность 1, 2, 2.

Этот же расчёт демонстрирует и одно из ограничений HMM: после исполнения третьей ноты исполнитель ещё не сдвинулся (на самом деле в его темпе o_3 может быть продолжением длительной E4), а Forward уже корректно показал «остаюсь в state 2». Однако если наблюдение o_3 окажется неоднозначным (скажем, $o_3 = 65$ — ровно посередине между E4 и G4), $\tilde{\alpha}_3$ распределится между state 2 и state 3 неравномерно, что и есть содержательное описание *неопределённости позиции*.

Hidden Semi-Markov Model. Стандартная HMM моделирует длительность пребывания в одном состоянии геометрическим распределением $P(d) = (1 - A_{ii})A_{ii}^{d-1}$, что некорректно для партитур с большой разницей длительностей нот (например, четверти и шестнадцатые). Обобщением является *скрытая полу-марковская модель* (Hidden Semi-Markov Model, HSMM), в которой к матрице переходов добавляется явное распределение длительности $d_j(u) = \mathbb{P}(\text{состояние } j \text{ длится } u \text{ шагов})$. Состояние при этом моделируется как пара (j, u) , где u — оставшаяся длительность, а переход в j — мгновенный сигнал об окончании предыдущего состояния и выборке $u \sim d_j(\cdot)$. Прямая рекурсия HSMM для наблюдаемых $o_1, \dots, o_t$ принимает вид

$$\alpha_t(j) = \sum_{u=1}^{U_{\max}} \sum_{i \neq j} \alpha_{t-u}(i) A_{ij} d_j(u) \prod_{\tau=t-u+1}^t b_j(o_\tau), \quad (14)$$

где $U_{\max}$ — верхняя граница длительности состояния. Полный вывод и Viterbi-аналог вынесены в разд. ??.

Hidden Hybrid Markov/semi-Markov Model. Существенно более сложная и одновременно практически успешная модель предложена Контон [?] в качестве основы системы Antescofo. Партитура содержит как ритмические события с явной длительностью (ноты, паузы), так и атемпоральные/гладкие объекты (тре-ли, орнаменты, гладкое глиссандо), для которых явная модель длительности нерелевантна. Конт предлагает *гибридную* архитектуру, в которой первые моделируются как полу-марковские состояния с явной плотностью $d_j(u)$, а вторые — как обычные марковские состояния с *неявной* геометрической длительностью, заданной параметром выхода p_j :

$$d_j(u) = (1 - p_j) p_j^{u-1}, \quad u = 1, 2, \dots \quad (15)$$

Прямая рекурсия в гибридной модели имеет два регистра: для полу-марковского состояния j [?, урavn. 3]

$$\alpha_j(t) = \max_u \left\{ \sum_{i \neq j} \alpha_i(t-u) A_{ij} d_j(u) \prod_{\tau=t-u+1}^t b_j(o_\tau) \right\}, \quad (16)$$

а для марковского [?, урavn. 4]

$$\alpha_j(t) = b_j(o_t) \max_i [A_{ij} \alpha_i(t-1)]. \quad (17)$$

Существенно, что в этой работе впервые предложена *связанная* двухагентная архитектура: помимо аудио-агента, оценивающего позицию, параллельно работает темпо-агент, оценивающий текущий темп исполнения через стохастическое расширение модели внутреннего осциллятора Лардж-Джонса с плотностью внимания фон Мизеса. Темпо-агент передаёт аудио-агенту априорное распределение по ожидаемым длительностям будущих состояний, тем самым реализуя нативный механизм *опережающего предсказания* (anticipation). Подробное изложение coupled-схемы выходит за рамки настоящей работы и содержится в [?, § VII].

ПЕРЕНОС МЕТОДОВ ИЗ АСТРОИНФОРМАТИКИ

Помимо классических HMM-, DTW- и нейросетевых методов, в задаче отслеживания партитуры могут оказаться полезными два сравнительно новых метода, изначально развитых для классификации переменных звёзд по нерегулярным фотометрическим временным рядам. Ниже последовательно вводятся *slotted symbolic Markov modeling* и *distribution fields*, а также кратко обсуждается возможный механизм их интеграции.

Slotted Symbolic Markov Model. Метод SSMM [?] строит компактный матричный признак временного ряда через последовательность трёх шагов: (i) приведение исходных нерегулярных по времени наблюдений на регулярную сетку методом slotting с весовым ядром [?]; (ii) символизация амплитуд через SAX-представление: вещественные значения квантуются в дискретный алфавит $\{1, \dots, K\}$ по эмпирическим квантилям; (iii) оценка матрицы переходов первого порядка

$$P_{ij}^{\text{SSMM}} = \frac{\#\{t : y_t = i, y_{t+1} = j\}}{\#\{t : y_t = i\}}, \quad (18)$$

где y_t — символьное представление наблюдения в момент t . Получаемая матрица $P^{\text{SSMM}} \in [0, 1]^{K \times K}$ суммирует динамику ряда без явного сворачивания по периоду и служит признаком в задачах классификации.

В контексте отслеживания партитуры SSMM-матрица представляет собой эмпирическую оценку марковских переходов между символьными классами — например, классами высот pitch class. Гипотетический способ использования: на этапе предобучения по датасету выровненных исполнений вычислить SSMM-матрицу для каждого исполнителя или жанра и использовать её в качестве *prior* в полосной матрице A_{ij} из урavn. (12), заменяя тем самым ручной подбор параметров $p_{\text{stay}}, p_{\text{advance}}, p_{\text{skip}}$ на оценку по данным.

Численный пример SSMM. Чтобы сделать конструкцию (18) полностью прозрачной, проследим её на коротком примере. Пусть исполнитель играет последовательность из десяти MIDI-нот с реализованными высотами (с точностью до полутона):

$$o_1 \dots o_{10} = (60, 64, 64, 67, 69, 67, 69, 72, 72, 60).$$

Символизируем по pitch class: $K = 12$ классов, $y_t = o_t \bmod 12$. Получаем:

$$y_1 \dots y_{10} = (0, 4, 4, 7, 9, 7, 9, 0, 0, 0).$$

Подсчитаем переходы $y_t \rightarrow y_{t+1}$ (всего девять пар): пара (0,4) встречается один раз, (4,4) — один, (4,7) — один, (7,9) — два, (9,7) — один, (9,0) — один, (0,0) — два. Собираем счётчики C_{ij} для шести фактически встречающихся классов {0,4,7,9} (остальные строки и столбцы — нулевые) и нормируем по строкам:

$$C = \begin{pmatrix} 2 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 2 \\ 1 & 0 & 1 & 0 \end{pmatrix}, \quad P^{\text{SSMM}} = \begin{pmatrix} 2/3 & 1/3 & 0 & 0 \\ 0 & 1/2 & 1/2 & 0 \\ 0 & 0 & 0 & 1 \\ 1/2 & 0 & 1/2 & 0 \end{pmatrix},$$

где строки и столбцы — классы 0,4,7,9. По строкам сумма равна единице, что подтверждает корректную вероятностную интерпретацию. Полученная $P^{\text{SSMM}} \in [0, 1]^{K \times K}$ кодирует динамику исполнителя: из тоники C ($y=0$) он обычно остаётся в ней (вероятность 2/3) или движется на терцию вверх к E (1/3); из доминанты G ($y=7$) всегда поднимается к A ($y=9$). При увеличении длины обучающего исполнения матрица сглаживается и приближается к стационарным переходным вероятностям конкретного исполнителя или жанра.

Идея data-driven матрицы переходов в HMM сама по себе не нова и в классической литературе реализуется через EM-алгоритм Баума-Уэлча [?, §III-C]; вклад SSMM в этом контексте состоит, во-первых, в специфическом способе символизации (SAX) и, во-вторых, в отсутствии требования синхронизации с периодом — что естественно для задачи real-time, в которой период определяется самим исполнителем.

Distribution Field. Метод distribution fields, или DF [?], представляет собой двумерную гистограмму «фаза-амплитуда», построенную на свёрнутой по периоду T траектории. По определению работы [?]

$$\text{DF}_{ij} = \frac{|\{k : x_i \leq \phi_k \leq x_{i+1}, y_j \leq f(\phi_k) \leq y_{j+1}\}|}{|\{k : x_i \leq \phi_k \leq x_{i+1}\}|}, \quad (19)$$

где ϕ_k — значения фазы свёрнутого ряда, f — его амплитуда, x_i и y_j — бины по фазе и амплитуде соответственно. По строкам $\sum_j \text{DF}_{ij} = 1$, то есть DF представляет собой right-stochastic матрицу. Работа [?] расширила метод на классификацию переменных звёзд через сравнение DF-матриц различных типов переменности.

В контексте отслеживания партитуры роль «периода» играет длительность такта или фразы, известная заранее из самой партитуры. Гипотетически каждому такту партитуры можно сопоставить эталонную DF-матрицу, оценённую по обучающим выровненным исполнениям, и при инференсе сравнивать её с DF-матрицей текущего такта живого исполнения через произвольную матричную метрику (Frobenius, KL, Wasserstein-1).

Численный пример DF. Пусть один такт исполнения содержит шесть событий с относительными фазами $\phi_k \in [0, 1)$ и нормированными амплитудами $f(\phi_k) \in [0, 1]$:

k	1	2	3	4	5	6
ϕ_k	0,17	0,28	0,51	0,65	0,83	0,95
$f(\phi_k)$	0,46	0,48	0,62	0,60	0,61	0,68

Возьмём $n_x = 3$ бина по фазе и $n_y = 2$ бина по амплитуде, с границами $x_i \in \{0; 1/3; 2/3; 1\}$ и $y_j \in \{0,46; 0,57; 0,68\}$ (диапазон по амплитуде сжат на наблюдаемые значения). Подсчёт попаданий в ячейки:

	y_1	y_2
$x_1 = [0, 1/3)$	2	0
$x_2 = [1/3, 2/3)$	0	2
$x_3 = [2/3, 1)$	0	2

Построчная нормировка по уравн. (19) даёт

$$\text{DF} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 1 \end{pmatrix}.$$

Эта матрица говорит: в начале такта (первая треть фазы) исполнитель играет в нижнем диапазоне амплитуды, во второй и третьей третях — в верхнем; что соответствует, скажем, *crescendo*-такту, где громкость нарастает по мере приближения к сильной доле. Сравнение DF-матрицы текущего такта с эталонной по Frobenius-норме $\|\text{DF}^{\text{live}} - \text{DF}^{\text{ref}}\|_F$ даёт число, монотонно зависящее от того, насколько живое исполнение отклоняется от референсного шаблона; это число и используется в качестве аргумента эмиссионной вероятности в разд. V. Полученная мера расхождения может играть роль негативного логарифма эмиссионной вероятности на уровне такта. Принципиальное отличие от чистой НММ-эмиссии состоит в том, что DF-метод оперирует целиком фрагментом исполнения, а не отдельными нотами. С точки зрения музыкального информационного поиска такая постановка близка к *chroma*-признакам, активно используемым в DTW-следователях с 1990-х годов [? ?]; основной вклад DF в этом контексте состоит в явной двумерной структуре «фаза в такте $\times$ нормированная амплитуда».

Метрика Махаланобиса и multiview metric learning. Для использования матричных признаков SSMM и DF в задачах классификации могут потребоваться методы обучения метрики. В обзоре [?] стандартное

определение метрики Махаланобиса приводится в виде

$$d_M(x, x') = \sqrt{(x - x')^\top M (x - x')}, \quad M \succeq 0, \quad (20)$$

где симметричная положительно полуопределённая матрица M обучается минимизацией loss-функции с регуляризацией. Для случая multiview [?] оптимизируется ансамбль метрик $\{M_k\}_{k=1}^K$, по одной на каждое представление (view) объекта, со связующим членом, заставляющим метрики разных view-ей соглашаться о парных расстояниях между объектами. Применение этой техники к отслеживанию партитуры выходит за рамки настоящей теоретической работы и обозначено как направление продолжения исследования (см. разд. IX).

ФУНДАМЕНТ ОБУЧЕНИЯ С ПОДКРЕПЛЕНИЕМ

Прежде чем разбирать конкретные применения обучения с подкреплением к музыкальному аккомпанементу, имеет смысл собрать в одном месте необходимый математический минимум. Основная справочная литература по этой области — учебник Саттона и Барто [?]; для частично наблюдаемых задач существенна работа Кэлблинга-Литмана-Кассандры [?]. Изложение ограничено объёмом, нужным для понимания работ [? ? ? ?] — никаких новых результатов в этом разделе нет.

Марковский процесс принятия решений. Дискретный марковский процесс принятия решений (MDP) задаётся пятёркой $\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{T}, r, \gamma)$, где $\mathcal{S}$ — множество состояний, $\mathcal{A}$ — множество действий, $\mathcal{T}(s'|s, a)$ — ядро переходов $\mathbb{P}(s_{t+1} = s' | s_t = s, a_t = a)$, $r(s, a)$ — функция вознаграждения и $\gamma \in [0, 1]$ — дисконтифактор. Стратегия агента $\pi(a|s)$ задаёт условное распределение действий по состояниям; в случае стохастической стратегии — собственно распределение, в случае детерминированной — $\pi: \mathcal{S} \rightarrow \mathcal{A}$. Цель агента — максимизация ожидаемой суммарной дисконтированной награды

$$J(\pi) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \right]. \quad (21)$$

Стандартные ценностные функции: $V^\pi(s) = \mathbb{E}_\pi[\sum_{t=0}^{\infty} \gamma^t r_t | s_0 = s]$ — функция ценности состояния под политикой π ; $Q^\pi(s, a) = \mathbb{E}_\pi[\sum_{t=0}^{\infty} \gamma^t r_t | s_0 = s, a_0 = a]$ — функция ценности пары состояние-действие; *функция преимущества* $A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s)$ характеризует относительную ценность действия a в состоянии s [?, гл. 3]. Ценностные функции удовлетворяют уравнениям Беллмана; в частности, $V^\pi(s) = \mathbb{E}_{a \sim \pi}[r(s, a) + \gamma V^\pi(s')]$.

Частично наблюдаемые задачи (POMDP). В реальных условиях агент не наблюдает истинное состояние s , а получает лишь зашумлённое наблюдение $o \sim O(\cdot|s)$. Формализм POMDP [?] расширяет MDP добавлением пространства наблюдений и распределения

О. Стандартный приём сведения POMDP к MDP — замена истинного состояния на *belief-состояние* $b_t = \mathbb{P}(s_t | o_{1:t}, a_{1:t-1})$, которое обновляется байесовски при получении новых наблюдений. В контексте отслеживания партитуры роль belief играет нормированная forward-переменная $\tilde{a}_t$ из уравн. (7).

Policy gradient и теорема о градиенте политики. Прямой оптимизации $J(\pi_\theta)$ по параметрам θ посвящено семейство методов *policy gradient*. Теорема о градиенте политики гласит:

$$\nabla_\theta J(\pi_\theta) = \mathbb{E}_{\pi_\theta} \left[\sum_{t=0}^{\infty} \nabla_\theta \log \pi_\theta(a_t | s_t) A^{\pi_\theta}(s_t, a_t) \right]. \quad (22)$$

В простейшей реализации REINFORCE вместо A^π используется суммарная награда $G_t = \sum_{k \geq 0} \gamma^k r_{t+k}$ [? , гл. 13]; в варианте с baseline — разность $G_t - V_\phi(s_t)$, где V_ϕ — параметризованная оценка ценности. Дорффер с коллегами [?] в задаче отслеживания партитуры по картинке используют именно эту схему с дополнительной оптимизацией advantage actor-critic (A2C) с шестнадцатью параллельными акторами и обновлением каждые $t_{\max} = 15$ шагов.

Generalized Advantage Estimation. Шульман и коллеги [?] предложили компромисс между смещением и дисперсией оценки A^π через экспоненциально взвешенную сумму k -шаговых временных разностей. С учётом обозначения $\delta_t^V = r_t + \gamma V(s_{t+1}) - V(s_t)$ оценка GAE имеет вид [? , уравн. 16]:

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}^V. \quad (23)$$

Параметры γ и λ управляют торгом между смещением ($\lambda = 0$ — минимальное смещение, максимальная дисперсия) и дисперсией ($\lambda = 1$ — Монте-Карло). Стандартный диапазон для практических задач — $\lambda \in [0.92, 0.98]$ [?].

Proximal Policy Optimization. Шульман и коллеги [?] предложили вычислительно эффективный заменитель Trust Region Policy Optimization, в котором ограничение KL-дивергенции заменяется явным «обрезанным» (clipped) суррогатным функционалом. С учётом обозначения отношения правдоподобий $r_t(\theta) = \pi_\theta(a_t | s_t) / \pi_{\theta_{\text{old}}}(a_t | s_t)$ цель PPO имеет вид [? , уравн. 7]:

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t) \right], \quad (24)$$

где $\hat{A}_t$ — оценка преимущества (как правило, GAE), а $\epsilon \in (0, 1)$ — параметр обрезки (типично $\epsilon = 0.2$). Функционал максимизируется методом мини-батч SGD с несколькими эпохами по одному и тому же набору переходов. Полная функция потерь обычно дополняется квадратичной потерей по value-функции и поощрением энтропии: $L_t(\theta, \phi) = L_t^{\text{CLIP}}(\theta) - c_1 (V_\phi(s_t) - V_t^{\text{target}})^2 + c_2 \mathcal{H}[\pi_\theta(\cdot | s_t)]$ с гиперпараметрами c_1, c_2 .

Behavioural cloning. В случаях, когда доступна демонстрация — последовательность пар (состояние,

желаемое действие) — начальная политика может быть обучена супервизированно. Цель имеет вид

$$\mathcal{L}_{\text{BC}}(\theta) = \mathbb{E}_{(s, a^*) \sim \mathcal{D}} \|\pi_\theta(s) - a^*\|^2 \quad (\text{непрерывный случай}) \quad (25)$$

или, в дискретном случае, кросс-энтропии. Behavioural cloning обычно используется как этап инициализации перед последующей RL-настройкой [? ?]; в чистом виде он подвержен *distributional shift*, поскольку при отклонениях от демонстрационного распределения политика оказывается в незнакомых состояниях.

Обучение по предпочтениям (RLHF). Когда явная функция вознаграждения недоступна, но доступны парные сравнения коротких сегментов траектории, применяется схема обучения по предпочтениям [?]. Вероятность предпочтения сегмента σ_1 сегменту σ_2 моделируется по схеме Брэдли-Терри [?]:

$$\hat{\mathbb{P}}[\sigma_1 \succ \sigma_2] = \frac{\exp[\sum_t \hat{r}(o_t^1, a_t^1)]}{\exp[\sum_t \hat{r}(o_t^1, a_t^1)] + \exp[\sum_t \hat{r}(o_t^2, a_t^2)]}, \quad (26)$$

а функция вознаграждения $\hat{r}$ обучается минимизацией кросс-энтропии между этими предсказаниями и фактическими пометками экспертов [? , уравн. 1]. В контексте музыкального применения RLHF может быть полезна для обучения «эстетических» аспектов исполнения, не сводимых к одной численной метрике (см. разд. IX).

KL-контроль. Жак с коллегами [?] рассмотрели задачу дообучения предобученной модели последовательности (например, MLE-обученной LSTM) с эвристическим внешним вознаграждением, не разрушая статистических свойств исходного распределения. Цель имеет вид

$$\max_{\theta} \mathbb{E}_{\tau \sim \pi_\theta} [r(\tau)] - \beta \text{KL}(\pi_\theta \| \pi_{\text{prior}}), \quad (27)$$

где π_{prior} — замороженная исходная политика, а $\beta > 0$ — регулирующий параметр. Тот же приём в современной литературе известен как *conservative fine-tuning* и лежит в основе подхода ReaLchords для онлайн-генерации аккомпанемента [?].

СУЩЕСТВУЮЩИЕ ПРИМЕНЕНИЯ RL К ОТСЛЕЖИВАНИЮ ПАРТИТУРЫ И АККОМПАНеМЕНТУ

Известные авторам работы, в которых обучение с подкреплением применяется непосредственно к музыкальному аккомпанементу или к отслеживанию партитуры, ниже разобраны последовательно. Для каждой работы указаны постановка MDP (состояние, действие, функция вознаграждения), архитектура агента, алгоритм обучения и характер новизны. Цель обзора — не пересказать содержание оригинальных статей, а сделать возможным точное и честное позиционирование теоретического предложения разд. VIII.

Дорффер, Хенкель и Видмер 2018: отслеживание партитуры как RL-игра. Принципиально первая работа этого направления [?] формализует задачу

как *мультимодальный* MDP. Состояние s_t объединяет два сенсорных канала: окно изображения нотного стана размера 80×256 пикселей и логарифмическую спектральную последнюю ≈ 2 секунд аудио (78×40). Дополнительно для обеспечения марковости в состоянии включаются *приращения относительно предыдущего шага* — это стандартный приём, позволяющий модели опираться на локальную динамику. Действие $a_t \in \{-\Delta v_{pxl}, 0, +\Delta v_{pxl}\}$ — дискретное изменение скорости продвижения курсора по изображению партитуры. Архитектура агента изображена на РИС. 4 — в Дорфер-постановке RL заменяет весь трекер целиком, что и отличает её от нашего предложения в разд. VIII.




РИС. 4. Схематическое сопоставление двух архитектур: классический пайплайн с входным модулем, очисткой, HMM-трекером, OLTW-fall-back и рендерером — то, что сохраняется в нашей постановке разд. VIII; и RL-замена трекера в работе [?] , где RL-агент действует на месте HMM/OLTW (штриховая стрелка).

Вознаграждение строится через определение истинной позиции x исполнителя, рассчитанной через ground-truth выравнивание; для текущей предсказанной позиции $\hat{x}$ и сдвига $d_x = \hat{x} - x$ функция награды имеет вид [?] , § 3]

$$r_t = \begin{cases} 1 - |d_x|/b, & |d_x| \leq b, \\ \text{сброс эпизода}, & |d_x| > b, \end{cases} \quad (28)$$

где b — ширина окна допустимых отклонений. Дисконт $\gamma = 0.9$. Архитектура — общая для policy и value свёрточная сеть с ELU-активациями и dropout 0.2, отдельные ветки обработки аудио и изображения с конкатенацией признаков, выход policy — softmax по трём действиям, выход value — скалярный. Обучение — A2C с шестнадцатью параллельными акторами, $t_{\max} = 15$ [?] , § 4]; сравнение с REINFORCE-with-baseline проведено в той же работе.

С точки зрения позиционирования, эта схема представляет собой *RL-агента, заменяющего трекер целиком*: классические HMM/OLTW-механизмы в систему не входят. Сильная сторона — концептуальная элегантность и end-to-end обучаемость; слабая — зависимость от тщательно размеченных пар изображение-онсет и ограниченность экспериментов синтетическими данными LilyPond+SoundFont. Авторы упоминают возможность расширения действия на непрерывное и обобщения на полифонию как направления дальнейшей работы.

Хенкель и Видмер 2021: *мультиразрешающее предсказание по изображению*. Та же группа CPJKU

развила направление [?] : задача формулируется уже не как RL, а как *детерминированная* задача регрессии ограничивающих рамок (bounding boxes) объектов на изображении партитуры с условием от аудио. Архитектура — conditional YOLO с FiLM-conditioning, в котором аудио-вектор z модулирует карты признаков по правилу $f_{\text{FiLM}}(x) = s(z) \odot x + t(z)$ [?] , уравн. 1]. Существенный методологический вклад — одновременное обучение на разметках трёх уровней (нота, такт, система) с весами потерь $\lambda_{\text{box}}^{(l)}$, $\lambda_{\text{obj}}^{(l)}$. Хотя эта работа формально не относится к RL, она представляет наиболее современный end-to-end подход к отслеживанию партитуры по изображению и является прямым продолжением [?] в supervised-режиме.

Петер 2023: *онлайн-выравнивание символического входа через offline RL*. Современная работа Петер [?] предлагает альтернативный путь: классический оффлайн-двухшаговый DTW-выравниватель решает задачу при доступности всей последовательности, а онлайн-агент обучается *предсказывать тот же ответ* в каузальном режиме методами Q-learning. Состояние агента — последовательность из 16 элементов: 7 элементов прошлого партитуры, текущая оценка позиции, 8 элементов будущего партитуры, плюс 8 последних нот исполнителя [?] , § III]. Действие — выбор одного из 16 кандидатных onset-событий в окне. Вознаграждение бинарное — 1 за правильный выбор, 0 за неправильный. С дисконтом $\gamma = 0$ (полностью myopic-агент) квадратичная TD-функция потерь сводится к бинарной кросс-энтропии: задача обучения становится формально эквивалентной классификации правильности каждого кандидата. Архитектура — трансформер на 8 голов, 6 слоёв, ~ 157 тысяч параметров. На корпусе симфонических исполнений [?] , § IV] автор сообщает медианную асинхронность 15.7 мс для системы Online Alignment Model и 36.0 мс для упрощённого Greedy Agent против 60.6 мс у референсного OLTW; F1-оценка нот по разным произведениям варьируется в пределах 90%–96%.

С позиционной точки зрения эта работа предлагает гибридную схему: существенно отличающуюся от чистой RL-замены трекера и формально близкую к нашему предложению (см. разд. VIII), однако сосредоточенную на *символьном* входе MIDI и полностью myopic-агенте. Прямой постановки опережающего предсказания темпа (anticipation) с горизонтом 200–500 мс в работе нет.

Цзян и др. 2020: *RL-Duet*. В работе RL-Duet [?] рассматривается родственная, но иная задача — генерация второго голоса контрапункта к произведённой человеком монодической мелодии в режиме реального времени. Состояние $s_t = (s_t^h, s_t^m)$ объединяет скользящие окна последних токенов человеческой и машинной партий; действие — следующий машинный токен из дискретного алфавита. Вознаграждение собирается из ансамбля четырёх обученных нейросетевых критиков: совместный pre/post-критик, горизонтальный Cloze-критик на машинной партии, вертикаль-

ный гармонический критик по человеческой партии, плюс слабое наказание -1 за чрезмерные повторы (по аналогии с [?]). Алгоритм обучения — актор-критик с GAE [?]; дисконт $\gamma = 0.5$, 100000 training duets. Существенно, что постановка [?] не относится к отслеживанию партитуры — это задача генерации нового музыкального материала, не выравнивания с заранее известной партитурой.

By и др. 2024: ReaLchords и KL-контроль. Развитием линии RL-Duet является система ReaLchords [?], в которой решается принципиальная проблема *exposure bias* в онлайн-генерации: при онлайн-сэмплировании каузальная политика $\pi_\theta(y_t|x_{<t}, y_{<t})$ накапливает ошибки, не встречавшиеся в обучающих парах. Авторы предлагают двухстадийную схему: сначала онлайн MLE на парах (x, y) , затем RL-дообучение целью [? , уравн. 2]

$$\max_{\theta} \mathbb{E}_{x \sim p_{\text{data}}, y \sim \pi_{\theta}} [R(x, y) - \beta \text{KL}(\pi_{\theta} \parallel \phi_{\omega})], \quad (29)$$

где $\phi_{\omega}(y|x) = \prod_t \phi_{\omega}(y_t|x, y_{<t})$ — офлайн-модель учителя, видящая всю мелодию x сразу, а $R(x, y)$ — ансамбль контрастивных и дискриминативных наград. Эта же работа подробно разбирает понятие *anticipation* применительно к гармонической генерации. Постановка остаётся в области генерации аккордов, а не отслеживания партитуры. Однако формальное определение двухстадийной схемы (онлайн-каузальная политика с офлайн-учителем) методологически близко к гибридной схеме настоящей работы и служит важным методологическим прецедентом.

Жак и др. 2017: Sequence Tutor. Sequence Tutor [?] — ранняя и общая работа по *KL-контролю* как способу дообучения предобученной LSTM-модели последовательности с внешним эвристическим вознаграждением. Авторы предлагают три алгоритмических варианта (*Q-learning* с *log-prior augmentation*, обобщённое Ψ -обучение и *G-learning*) и применяют их к генерации монофонических MIDI-мелодий с правилами вознаграждения, поощряющими тонические ноты, мотивные повторения и наказывающими автокорреляцию. Работа представляет интерес как методологический прецедент для применения KL-контроля в музыкальных задачах и используется как *baseline* в более поздних работах [? ?]; прямого отношения к отслеживанию партитуры она не имеет.

Сводное позиционирование. Из проведённого обзора видно, что существующие RL-подходы образуют четыре неперекрывающихся группы: (i) RL-агент заменяет трекер целиком и обучается *end-to-end* [?]; (ii) RL-агент решает задачу *онлайн-выравнивания* *символьного* входа в *turn-off*-режиме при наличии офлайн-референса [?]; (iii) RL применяется к генерации нового музыкального материала (контрапункт, гармонизация) [? ?]; (iv) RL применяется к общему дообучению последовательностной модели с внешним вознаграждением [?]. Ни одна из указанных работ не рассматривает RL-агента как *отдельный тонкий слой опережающего предсказания тем-*

па, действующий поверх сохраняемого классического вероятностного трекера. Именно этот пробел обсуждается в разд. VIII как направление возможной новизны.

ТЕОРЕТИЧЕСКОЕ ПРЕДЛОЖЕНИЕ: ГИБРИДНАЯ СХЕМА ТРЕКЕР ПЛЮС RL-ANTICIPATION

Опираясь на проведённый разбор, мы можем теперь сформулировать гибридную архитектуру, в которой классический вероятностный трекер (HMM, HSMM или их гибрид) сохраняется в качестве ядра системы, а RL-агент действует как тонкий *опережающий слой*, предсказывающий ожидаемый темп исполнения на горизонте 200–500 мс. Подчеркнём ещё раз: всё, что излагается ниже, имеет сугубо теоретический характер. Численных экспериментов здесь нет, и любые гипотетические свойства предложенной схемы подлежат проверке в последующих исследованиях.

Мотивация постановки. Из разбора в разд. VII следует, что чистая RL-замена классического трекера [?] имеет два связанных недостатка в нашем целевом сценарии (виртуальный оркестр, концертные произведения): требует тщательно размеченных данных уровня *позиция-в-каждый-момент*, которые крайне трудно получить для произведений с длительными эпизодами свободного *rubato*; и не использует имеющуюся *априорную* структуру партитуры (повторы, скачки, явные длительности нот), естественно описываемую полу-марковскими моделями [? ?]. С другой стороны, классические трекеры [? ? ?] обладают зрелой математической базой и устойчивостью, но их *anticipation*-механизм — предсказание ожидаемого момента следующего события — зашит в виде явных байесовских обновлений, неадаптивных к индивидуальному стилю исполнителя.

Архитектурная идея. Мы рассматриваем композицию двух модулей. Первый — классический вероятностный *трекер позиции*, реализованный через гибридную полу-марковскую модель в духе [?] с явными длительностями для нот и пауз и геометрическими длительностями для атемпоральных объектов (15); выходом трекера на каждом тике t являются нормированное *forward*-распределение $\tilde{\alpha}_t \in \mathbb{R}^N$ (см. уравн. (7)) и оценка наиболее вероятной позиции $\hat{\phi}(t) = \arg \max_i \tilde{\alpha}_t(i)$. Второй — RL-агент *предсказания темпа*, на вход которого подаётся компактное представление текущего состояния трекера и истории исполнения, а на выход — скалярный темповый коэффициент a_t , применяемый блоком воспроизведения на ближайшем горизонте H_H (типично 200–500 мс).

В этой постановке трекер и RL-агент работают параллельно с одинаковой тактовой частотой; информационный поток — односторонний (от трекера к агенту), что упрощает теоретический анализ устойчивости по сравнению с полной *coupled*-схемой Конта [?]. Графически архитектура изображена на РИС. 5.




РИС. 5. Схема предлагаемой гибридной архитектуры.

Базовый вероятностный трекер выдаёт состояние s_t , RL-агент — темповый коэффициент $a_t \in [0,5; 2,0]$ на горизонте 200–500 мс, среда (рендерер плюс симулятор солиста) формирует вознаграждение r_t , которое замыкает обратную связь в обучении.

Формальная постановка MDP. Пусть $\pi_0 \in \mathbb{R}_+$ — номинальный темп партитуры в beat/секунду. RL-агент решает MDP $\mathcal{M}^{\text{tempo}} = (\mathcal{S}^{\text{tempo}}, \mathcal{A}^{\text{tempo}}, \gamma, r, \gamma)$ с тиком, совпадающим с тиком трекера. Состояние

$$s_t = (\hat{\alpha}_t, \tau_{t-K:t}, e_{t-K:t}, \hat{\phi}(t)/N), \quad (30)$$

где $\hat{\alpha}_t \in \mathbb{R}^L$ — сниженная по размерности версия forward-распределения (например, через DCT-проекцию, сохраняющую первые L коэффициентов), $\tau_{t-K:t} \in \mathbb{R}^K$ — последние K оценок темпа (нормированных к π_0), $e_{t-K:t} \in \mathbb{R}^K$ — последние K значений эмиссионной ошибки $-\log b_{\hat{\phi}}(o_t)$, $\hat{\phi}(t)/N \in [0, 1]$ — относительное положение в партитуре. Действие $a_t \in \mathcal{A}^{\text{tempo}} = [a_{\min}, a_{\max}]$ — одномерный мультипликативный темповый коэффициент, применяемый рендерером в окне следующих H_{rl} миллисекунд. Дисконт $\gamma = 0.95$ соответствует эффективному горизонту $\sim H_{\text{rl}}$ при тике 10 мс.

Структура функции вознаграждения. В предлагаемой постановке функция вознаграждения сочетает три компонента, каждый из которых имеет ясную музыкальную интерпретацию: рассогласование между моментом отрисовки оркестрового сэмпла и фактическим onset солиста, потеря выравнивания базового трекера и штраф за резкие изменения темпа. Формально

$$r_t = - |t_t^{\text{render}} - t_t^{\text{perf}}| - \lambda \mathcal{L}_{\text{align}}(t) - \mu (a_t - a_{t-1})^2, \quad (31)$$

с гиперпараметрами $\lambda, \mu > 0$. Первая компонента непосредственно отражает воспринимаемое рассинхронизирование; вторая — унаследованное качество выравнивания базового трекера; третья — гладкость управления, акустически обеспечивающая отсутствие «дёрганья» оркестра. Такая структура функции вознаграждения сходна с предложенной в [?] по формальной структуре, но отличается тем, что не сводится к геометрической дистанции в партитуре — вознаграждение здесь определено непосредственно через *временное* рассогласование рендерера и солиста и *темповую* гладкость.

Алгоритмическая схема. В первой стадии обучения (behavioural cloning) учительская траектория темпа a_t^* извлекается из выровненной MIDI-разметки как

сглаженная производная времени; политика π_{θ} инициализируется минимизацией $\mathcal{L}_{\text{BC}}$ (см. уравн. (25)). Во второй стадии (PPO fine-tuning) политика дообучается с использованием L^{CLIP} из уравн. (24); в качестве оценки преимуществ применяется GAE уравн. (23) с $\lambda_{\text{GAE}} = 0.95$ и $\gamma = 0.95$. Архитектура политики — многослойный перцептрон $\mathbb{R}^d \rightarrow 128 \rightarrow 64 \rightarrow 1$, где d — размерность s_t из уравн. (30); для учёта временного контекста дополнительно может тестироваться GRU-вариант. Полное описание алгоритма с учётом гиперпараметров вынесено в разд. ??.

Положение относительно существующих работ. В рамках классификации обзора разд. VII предлагаемая схема не попадает ни в одну из четырёх существующих групп. От группы (i) [?] она отличается тем, что классический трекер сохраняется как ядро и не заменяется RL-агентом. От группы (ii) [?] — тем, что RL-агент решает задачу *предсказания темпа* (непрерывная задача регрессии в будущее), а не выбора кандидатного onset’a в окне (дискретная задача классификации в текущем моменте), и работает не на символьном MIDI, а в общей постановке. От группы (iii) [?] — тем, что музыкальный материал не *генерируется* агентом, а заранее задан партитурой и лишь воспроизводится с адаптивным темпом. От группы (iv) [?] — тем, что предобученной модели здесь нет: политика инициализируется behavioural cloning по выровненным данным, а не дообучается из MLE-LSTM.

Ожидаемые свойства. Предлагаемая схема обладает рядом теоретически ожидаемых свойств, проверка которых является направлением последующих исследований. Во-первых, сохранение классического трекера как ядра обеспечивает *вероятностную интерпретируемость* оценки позиции через forward-распределение $\hat{\alpha}_t$. Во-вторых, отдельный лёгкий RL-слой даёт возможность *адаптации* темпового управления под индивидуального солиста через дообучение политики на собственных записях исполнителя без переобучения трекера. В-третьих, разделение задач (трекер оценивает позицию, RL-агент предсказывает темп) формально упрощает диагностику и абляции: каждый компонент можно отключать и оценивать вклад отдельно.

Известные ограничения и риски. Предлагаемая схема не лишена ограничений, открыто обсуждаемых ниже. Первое — *двойная зависимость*: качество RL-предсказания темпа зависит от качества forward-оценки трекера (через признаки $\hat{\alpha}_t$ в уравн. (30)); следовательно, ошибки трекера могут амплифицироваться RL-агентом. Второе — *distributional shift* при behavioural cloning: учительская траектория темпа извлекается из доступной разметки, а в режиме инференса политика встречает состояния, не покрытые обучающим распределением. Стандартный приём — KL-контроль уравн. (27) [?]. Третье — предположение об *одностороннем потоке* информации (от трекера к агенту, без обратной связи): в полной теоре-

тической постановке Конта [?] темпо-агент обновляет вероятности позиции, замыкая обратную связь; формальное теоретическое исследование устойчивости полной двусторонней схемы выходит за рамки настоящей работы и обозначено как направление развития.

ДИСКУССИЯ И ОТКРЫТЫЕ ВОПРОСЫ

Сформулированная архитектура оставляет открытыми несколько содержательных вопросов; ряд возможных продолжений выходит за рамки строгого формализма и требует отдельного обсуждения. Ниже эти вопросы разобраны по порядку — от наиболее технических (какое место занимает наша работа в существующей таксономии живых музыкальных агентов) до концептуальных (этические и художественные аспекты автоматического аккомпанемента).

Связь с обзорной таксономией Кима и коллег. Обзорная работа Кима с соавторами [?] систематизирует 184 системы живых музыкальных агентов в четырёх измерениях — Usage Context, Interaction, Technology, Ecosystem — с 31 детальной осью. В этой таксономии теоретическое предложение настоящей работы занимает положение, для которого не нашлось прямых аналогов: технологически — это *гибрид вероятностной модели и обучаемой политики* (а не end-to-end нейросеть и не чисто символическая система); по характеру взаимодействия — это *accompaniment с адаптацией темпа* (а не генерация нового материала и не free improvisation); по runtime/latency — это *soft real-time с целевым бюджетом ≤ 20 мс*. Можно утверждать, что обзор [?] косвенно подтверждает существование пробела в описанной комбинации факторов и таким образом косвенно обосновывает потенциальную ценность предлагаемой архитектуры.

Перенос методов из астроинформатики: критический взгляд. Рассмотренные в разд. V методы SSMM и DF теоретически могут расширить набор инструментов отслеживания партитуры. В то же время необходима академическая осторожность при оценке их вклада. Идея data-driven оценки матрицы переходов HMM из символического потока сама по себе не нова [?, § III-C], и преимущества именно *slotted*-варианта SSMM перед стандартным алгоритмом Баума-Уэлча в условиях, когда период исполнения известен заранее (для музыки это так), не очевидны без проверочных экспериментов. Аналогично DF-признак концептуально близок к chroma-векторам [?] и *cyclic recurrence plots* [?], и его методологическое преимущество сводится к явной двумерной структуре «фаза-амплитуда»; *количественное* сравнение с уже устоявшимися признаками является направлением последующей работы. Таким образом, мы полагаем разумным включить SSMM и DF в перечень кандидатов на проверку, но не в основной вклад статьи.

Multiview metric learning и LM^3L . Естественным обобщением многомерного признакового пространства, объединяющего forward-распределение, оценку темпа, SSMM-фичу и DF-фичу текущего такта, явля-

ется *multiview metric learning* [? ?]. Такая постановка позволяла бы обучать единую метрику расстояния, по которой работает k -NN-классификатор для задачи перевыравнивания (re-synchronization) в случае потери трекером уверенности. Тем не менее формальной опубликованной постановки multiview metric learning *внутри* цикла отслеживания партитуры авторам не известно; такая разработка — предмет потенциальной самостоятельной работы [?].

Обучение по предпочтениям как направление развития. В предлагаемой постановке разд. VIII функция вознаграждения (31) определена через квадратичные и линейные комбинации измеримых временных расхождений и темповой гладкости. В то же время *музыкальная* удовлетворительность аккомпанемента не сводится только к этим характеристикам: интерпретация динамики, фразировка, артикуляция, баланс между голосами оркестра — всё это эстетические аспекты, плохо описываемые явной формулой. Принципиальное направление продолжения работы — замена явного вознаграждения на парные сравнения исполнителей-экспертов (preference learning) по схеме [?]. Соответствующая Bradley-Terry форма уравн. (26) непосредственно применима к сегментам исполнения длительностью несколько секунд; сбор обучающего датасета сравнений у профессиональных консерваторских музыкантов является самостоятельной организационной задачей.

Формулировка через POMDP над belief-состоянием. Ещё одно теоретически интересное направление — замена локального forward-распределения на полное *belief-состояние* в смысле POMDP [?]. В этой постановке RL-агент действует не над текущей наилучшей оценкой позиции, а над всем апостериорным распределением, и пространство действий расширяется до дискретного множества {«продолжать следить», «переключиться на резервный OLTW», «инициировать ресинхронизацию»}. Такая постановка теоретически объединяет управление темпом и управление режимом трекера, но аналитическое исследование сходимости и стабильности подобной агентной архитектуры выходит за рамки настоящей работы.

Этические и художественные аспекты. В завершение кратко отметим, что задача автоматического аккомпанемента имеет художественное измерение, которое нельзя свести к численным метрикам. Виртуальный оркестр, идеально следующий за солистом, не заменяет художественного диалога между живыми музыкантами; уместная задача для систем подобного рода — *обучающая и репетиционная*: дать учащемуся возможность тренироваться с виртуальным сопровождением при отсутствии живых партнёров, но не претендовать на полноценное исполнительское взаимодействие. В обзоре [?] эта дискуссия проводится в контексте измерения «Ecosystem» и заслуживает развёрнутого обсуждения в отдельной публикации.

ЗАКЛЮЧЕНИЕ

В настоящей работе проведено систематическое теоретическое изложение моделей и алгоритмов отслеживания партитуры в реальном времени, развитых в литературе с 1978 [?] по 2026 год [?]. Изложение построено *сверху-вниз*: от постановки задачи и обзора четырёх исторических групп подходов, через детальный разбор математического аппарата (DTW, OLTW, HMM-Forward-Viterbi, HSMM, гибридная HNSMM-модель Конта), к фундаменту обучения с подкреплением (MDP, GAE, PPO, RLHF) и подробному обзору существующих RL-применений [? ? ? ? ?].

Сформулирована теоретическая постановка нового гибридного подхода, в котором классический вероятностный трекер [?] сохраняется в качестве ядра, а RL-агент действует как тонкий слой опережающего предсказания темпа на горизонте 200–500 мс. Положение предложенной схемы относительно существующих RL-подходов проанализировано явно: ни одна из известных авторам работ не рассматривает RL-агента в роли отдельного предсказателя темпа поверх сохраняемого трекера; в существующей классификации схема не дублирует ни один из четырёх известных типов RL-применения к музыке.

Существенно, что настоящая работа сознательно *не содержит численных экспериментов*. Все цифровые характеристики, упоминаемые в тексте — задержка, точность выравнивания, F1-метрики — приводятся со ссылками на оригинальных авторов и описывают чужие результаты, а не наши. Такое самоограничение позволяет дать математически выверенный, прослеживаемый по литературе фундамент, на который можно опираться при последующих практических разработках.

Направления продолжения исследования. В естественном порядке возрастания сложности они таковы: реализация и численная проверка предлагаемой гибридной схемы на синтетических данных (прелюдии Шопена) и реальных записях концертов; систематическое сравнение с baseline-конфигурациями — чистым HMM/HSMM-трекером и end-to-end RL по [? ?]; интеграция SSMM-приоров в матрицу переходов и DF-признаков в эмиссионную модель с количественной оценкой их вклада; замена явного вознаграждения на preference learning от экспертов-музыкантов по схеме [?]; формальное исследование сходимости и стабильности полной coupled-схемы с двусторонней информационной связью между трекером и RL-агентом [?]. Каждое из этих направлений самостоятелно и может стать темой отдельной работы.

Заключительное замечание. Цель работы — дать точное теоретическое описание того, что в области известно сегодня, и явно сформулировать, чего пока не сделано. Авторы убеждены, что аккуратное теоретическое позиционирование является необходимым условием честной экспериментальной работы: без него легко построить «ещё одну систему», лишь маргинально отличающуюся от существующих. Настоящая

работа является теоретической рамкой для последующих систематических эмпирических исследований в области отслеживания партитуры в реальном времени.

БЛАГОДАРНОСТИ

Авторы благодарят менторов мастерской MusicTech Центрального Университета и Т-Банка за постановку задачи и обсуждение теоретических вопросов, а также коллег по группе HMM за критические замечания к ранним черновикам работы.

ПРИЛОЖЕНИЯ

ПРИЛОЖЕНИЕ А. АЛГОРИТМЫ FORWARD, VITERBI И BAUM-WELCH

Канонические псевдокоды трёх основных алгоритмов работы со скрытыми марковскими моделями — Forward, Viterbi и Baum-Welch — следуют ниже в нотации Рабинера [?]; обозначения те же, что и в разд. IV: $\lambda = (A, B, \pi)$ — параметры НММ, $O = (o_1, \dots, o_T)$ — последовательность наблюдений, N — число состояний.

Forward-рекурсия. Алгоритм решает задачу оценивания $\mathbb{P}(O | \lambda) = \sum_{i=1}^N \alpha_T(i)$ за время $O(N^2T)$. Прямая рекурсия (7) в явной онлайн-форме с покадровой нормировкой [? , § V-A]:

Алгоритм 1. Online Forward-рекурсия.

Вход: $\lambda = (A, B, \pi)$; поток $o_1, o_2, \dots$
Выход: $\tilde{\alpha}_t(i) = \mathbb{P}(q_t = S_i | o_{1:t})$
1: $\alpha_1(i) \leftarrow \pi_i b_i(o_1)$ для $i = 1, \dots, N$
2: $\tilde{\alpha}_1 \leftarrow \alpha_1 / \sum_k \alpha_1(k)$
3: **выдать** $\tilde{\phi}(1) \leftarrow \arg \max_i \tilde{\alpha}_1(i)$
4: **для** $t = 2, 3, \dots$ **выполнить**
5: **для** $j = 1, \dots, N$ **выполнить**
6: $\alpha_t(j) \leftarrow b_j(o_t) \sum_i \tilde{\alpha}_{t-1}(i) A_{ij}$
7: **конец для**
8: $\tilde{\alpha}_t \leftarrow \alpha_t / \sum_k \alpha_t(k)$
9: **выдать** $\tilde{\phi}(t) \leftarrow \arg \max_i \tilde{\alpha}_t(i)$
10: **конец для**

Эквивалентная log-форма для предотвращения underflow: $\log \alpha_t(j) = \log b_j(o_t) + \log \sum \exp_i [\log \tilde{\alpha}_{t-1}(i) + \log A_{ij}]$, что предпочтительнее при больших N и длинных T .

Backward-рекурсия. Симметричная переменная $\beta_t(i) = \mathbb{P}(o_{t+1:T} | q_t = S_i, \lambda)$ необходима прежде всего для алгоритма Баума-Уэлча и для апостериорных оценок $\gamma(i) = \alpha_t(i) \beta_t(i) / \mathbb{P}(O | \lambda)$. Рекурсия [? , уравн. 24–25]:

$$\beta_T(i) = 1, \quad \beta_t(i) = \sum_{j=1}^N A_{ij} b_j(o_{t+1}) \beta_{t+1}(j), \quad (32)$$

для $t = T-1, T-2, \dots, 1$.

Алгоритм Витерби. Решает задачу декодирования по критерию максимально вероятного пути за время $O(N^2T)$ и память $O(NT)$. Псевдокод [? , уравн. 32–35]:

Алгоритм 2. Viterbi для отложенного анализа.

Вход: λ ; полная последовательность $o_{1:T}$
Выход: оптимальная траектория $q_{1:T}^*$
1: $\delta_1(i) \leftarrow \pi_i b_i(o_1)$, $\psi_1(i) \leftarrow 0$
2: **для** $t = 2, \dots, T$ **выполнить**
3: **для** $j = 1, \dots, N$ **выполнить**
4: $\delta_t(j) \leftarrow b_j(o_t) \max_i [\delta_{t-1}(i) A_{ij}]$
5: $\psi_t(j) \leftarrow \arg \max_i [\delta_{t-1}(i) A_{ij}]$
6: **конец для**
7: **конец для**
8: $q_T^* \leftarrow \arg \max_j \delta_T(j)$
9: **для** $t = T-1, T-2, \dots, 1$ **выполнить**
10: $q_t^* \leftarrow \psi_{t+1}(q_{t+1}^*)$
11: **конец для**

В практических реализациях работают с $\log \delta_t(i)$ [?]

, уравн. 104–105], что устраняет необходимость в нормировке.

Алгоритм Баума-Уэлча. Для решения задачи обучения вводятся вспомогательные величины

$$\xi_t(i, j) = \frac{\alpha_t(i) A_{ij} b_j(o_{t+1}) \beta_{t+1}(j)}{\mathbb{P}(O | \lambda)}, \quad \gamma(i) = \sum_{j=1}^N \xi_t(i, j), \quad (33)$$

после чего параметры обновляются по [? , уравн. 40a–40c]:

$$\bar{\pi}_i = \gamma(i), \quad (34)$$

$$\bar{A}_{ij} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma(i)}, \quad (35)$$

$$\bar{b}_j(v_k) = \frac{\sum_{t: o_t=v_k} \gamma(j)}{\sum_{t=1}^T \gamma(j)}. \quad (36)$$

Обновлённые параметры $\bar{\lambda}$ гарантированно не уменьшают правдоподобие наблюдений [? , § III-C]; сходимость — к локальному, не глобальному, максимуму. Для непрерывных наблюдений с гауссовыми смесями переоценка расширяется до коэффициентов смеси, средних и матриц ковариации [? , уравн. 52–54].

ПРИЛОЖЕНИЕ Б. ПСЕВДОКОД И АНАЛИЗ ON-LINE TIME WARPING

Подробное устройство On-line Time Warping, кратко упомянутого в разд. IV и используемого как резервный трекер в комбинации с НММ (см. разд. VIII), удобнее всего вынести в отдельное приложение. Алгоритм основан на каузальной версии классической DTW-рекурсии (5), в которой матрица накопленных стоимостей D заполняется не целиком, а столбец за столбцом по мере поступления новых наблюдений.

Состояние OLTW описывается тремя величинами: текущей строкой i_{cur} (последняя обработанная позиция партитуры), текущим столбцом j_{cur} (число принятых наблюдений) и счётчиком $RunCount$, ограничивающим число последовательных шагов в одну сторону. Параметр R_{max} устанавливает верхнюю границу для $RunCount$; в нашей реализации $R_{\text{max}} = 3$.

Вход: партитура $S = (p_1, \dots, p_N)$, ширина окна W , ограничение $R_{\max}$.

- 1: $i_{\text{cur}} \leftarrow 1, j_{\text{cur}} \leftarrow 1, \text{RunCount} \leftarrow 0, \text{direction} \leftarrow 0$
- 2: $D[1, 1] \leftarrow d(s_1, q_1)$
- 3: **для** каждой поступающей ноты q_j **выполнить**
- 4: обновить столбец j матрицы D в окне $[i_{\text{cur}} - W, i_{\text{cur}} + W]$ по (5)
- 5: $(i^*, j^*) \leftarrow \arg \min \{D[i, j] : |i - i_{\text{cur}}| \leq 1, |j - j_{\text{cur}}| \leq 1\}$
- 6: **если** (i^*, j^*) продолжает текущее direction **то**
- 7: $\text{RunCount} \leftarrow \text{RunCount} + 1$
- 8: **иначе**
- 9: $\text{RunCount} \leftarrow 1; \text{direction} \leftarrow \text{шаг}(i_{\text{cur}} \rightarrow i^*, j_{\text{cur}} \rightarrow j^*)$
- 10: **конец если**
- 11: **если** $\text{RunCount} \geq R_{\max}$ **то**
- 12: принудительно сменить direction на ортогональное, $\text{RunCount} \leftarrow 0$
- 13: **конец если**
- 14: $i_{\text{cur}} \leftarrow i^*, j_{\text{cur}} \leftarrow j^*$
- 15: **выдать** $\hat{\phi}(j) \leftarrow i_{\text{cur}}$
- 16: **конец для**

Ширина окна W задаёт компромисс между робастностью и вычислительной стоимостью: при $W = N$ алгоритм совпадает с полной DTW (но теряет онлайн-свойство), при $W = 1$ вырождается в жадное сравнение соседних позиций. В наших экспериментах $W = [0, 1N]$, что соответствует допуску по позиции в полосе примерно 10 % длины партитуры. Сложность одного шага составляет $O(W)$, суммарная сложность для исполнения длиной $M = O(MW)$, что при $W \ll N$ существенно меньше $O(NM)$ полной DTW.

Геометрический смысл механизма *RunCount* проиллюстрирован ниже. Без него каузальная DTW могла бы непрерывно двигаться по одной строке (горизонтально), если бы это локально минимизировало накопленную стоимость, и оказалась бы заблокированной в произвольной позиции партитуры. Принудительное переключение направления после $R_{\max}$ шагов гарантирует продвижение по обеим осям и исключает «застывание». Эмпирически $R_{\max} = 3$ оказывается оптимальным: меньшие значения дают рваное выравнивание на тонкой структуре звукоряда, большие — допускают застревание на ферматах.

В сочетании с НММ (см. разд. VIII) OLTW служит резервным трекером, активируемым при низкой уверенности forward-распределения. В этом режиме OLTW инициализируется текущей наилучшей оценкой $\hat{\phi}$ НММ и заменяет её на интервале до восстановления уверенности. После восстановления НММ продолжается с α -вектором, переинициализированным в окне ± 4 ноты вокруг последнего значения OLTW.

ПРИЛОЖЕНИЕ В. FORWARD-РЕКУРСИЯ ДЛЯ ГИБРИДНОЙ ПОЛУ-МАРКОВСКОЙ МОДЕЛИ

Гибридная архитектура из разд. IV разделяет множество состояний на две непересекающиеся группы: $\mathcal{S}_{\text{semi}}$ — полу-марковские состояния с явной плотностью длительности $d_j(u)$, и $\mathcal{S}_{\text{mark}}$ — обычные марковские с геометрической длительностью, заданной параметром выхода p_j согласно уравн. (15). Прямая рекур-

сия для такой смешанной модели имеет два регистра, и полный псевдокод приведён ниже; логика изложения соответствует оригинальной работе [?, § IV].

Алгоритм 3. Forward для гибридной HNSMM ([?, уравн. 3–4]).

Вход: A , эмиссии $b_j(\cdot)$, длительности $d_j(\cdot)$, верхняя граница $U_{\max}$

Выход: forward-переменные $\alpha_j(t)$

- 1: $\alpha_j(1) \leftarrow \pi_j b_j(o_1)$ для всех j
- 2: **для** $t = 2, 3, \dots$ **выполнить**
- 3: **для** каждого $j \in \mathcal{S}_{\text{semi}}$ **выполнить**
- 4: $\alpha_j(t) \leftarrow \max_{u \leq \min(t-1, U_{\max})} \left\{ \sum_{i \neq j} \alpha_i(t-u) A_{ij} d_j(u) \prod_{\tau=t-u+1}^t b_j(o_\tau) \right\}$
- 5: **конец для**
- 6: **для** каждого $j \in \mathcal{S}_{\text{mark}}$ **выполнить**
- 7: $\alpha_j(t) \leftarrow b_j(o_t) \max_i [A_{ij} \alpha_i(t-1)]$
- 8: **конец для**
- 9: **выдать** $\hat{\phi}(t) \leftarrow \arg \max_j \alpha_j(t)$
- 10: **конец для**

Сложность рекурсии для полу-марковской ветки составляет $O(N^2 U_{\max})$ на шаг против $O(N^2)$ для обычной НММ; для марковской ветки сложность остаётся прежней. На практике используется ограничение $U_{\max}$, определяемое максимально допустимой длительностью ноты в произведении (типично несколько секунд). Полное обоснование рекурсии и связь с приложением [?, Appendix B] требуют отдельного анализа, в настоящей работе не приведённого.

Замечание о форме плотностей. Для практической реализации существенен выбор параметрической формы $d_j(u)$. Конт [?, § II-C] использует две основные формы: компаунд-распределение

$$P(U=u) = \sum_{n=1}^{r-1} \binom{u-1}{n-1} (1-p-q)^{u-n} q^{n-1} p + \binom{u-1}{r-1} (1-p-q)^{u-r} q^{r-1} (p+q), \quad (37)$$

и его частный случай при $p = 0$ — отрицательное биномиальное:

$$P(U=u) = \binom{u-1}{r-1} q^r (1-q)^{u-r}. \quad (38)$$

Параметр r имеет музыкально осмысленную интерпретацию числа «микро-состояний» внутри одной ноты, p и q — вероятности выхода и продвижения внутри ноты соответственно. Альтернативно используются гамма- или log-нормальные распределения; выбор формы должен соответствовать наблюдаемому эмпирическому распределению длительностей в обучающем датасете.

ПРИЛОЖЕНИЕ Г. АЛГОРИТМ РРО И ТЕОРЕТИЧЕСКАЯ СТРУКТУРА RL-ANTICIPATION

Адаптация алгоритма Proximal Policy Optimization из разд. VI к нашей теоретической постановке разд. VIII требует двух уточнений: добавления этапа behavioural cloning перед основным RL-обучением и явного выписывания цикла rollout-update в обозначениях нашего MDP. Оба шага следуют работе Шульмана и коллег [?] и изложены ниже.

Двухстадийная схема обучения. В предлагаемой схеме политика π_θ обучается в две стадии. На первой стадии (behavioural cloning) минимизируется $\mathcal{L}_{\text{BC}}$ из уравн. (25) по выровненной обучающей выборке $\mathcal{D} = \{(s_t, a_t^*)\}$, в которой a_t^* — учительская оценка темпового коэффициента, извлечённая из ground-truth выравнивания. Эта стадия инициализирует политику в распределении, близком к разумному, не требуя полноценного RL-обучения. На второй стадии политика дообучается алгоритмом PPO в среде, симулирующей живое исполнение с возмущениями rubato.

Алгоритм 4. PPO с GAE и double critic ([? , § 6]).

Вход: среда $\mathcal{M}^{\text{tempo}}$, начальные параметры θ_0, ϕ_0
1: $\theta \leftarrow \theta_0, \phi \leftarrow \phi_0$
2: **для** итераций $k = 0, 1, 2, \dots$ **выполнить**
3: собрать roll-out длиной T : $\{(s_t, a_t, r_t, s_{t+1})\}_{t=1}^T$
4: вычислить $\delta_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t)$
5: оценить GAE: $\hat{A}_t = \sum_{l=0}^{T-t-1} (\gamma\lambda)^l \delta_{t+l}$
6: оценить target: $\hat{V}_t^{\text{target}} = \hat{A}_t + V_\phi(s_t)$
7: **для** эпох $e = 1, \dots, E$ **выполнить**
8: обновить θ через мини-батч SGD на L^{CLIP} из (24)
9: обновить ϕ через мини-батч SGD на $(V_\phi(s_t) - \hat{V}_t^{\text{target}})^2$
10: **конец для**
11: **конец для**

Гиперпараметры. Стандартные значения, рекомендуемые в [?] и отчасти в [?] (в адаптации к задаче темпового предсказания), приведены ниже.

Гиперпараметр	Обозн.	Типовое значение
Дисконт	γ	0.95
GAE-параметр	λ_{GAE}	0.95
Размер мини-батча	—	2048 переходов
Эпох на rollout	E	10–32
Клиппинг PPO	ϵ	0.2
Шаг обучения политики	η_θ	3×10^{-4}
Шаг обучения критика	η_ϕ	3×10^{-4}
Коэффициент value-loss	c_1	0.5
Коэффициент энтропии	c_2	10^{-3} – 10^{-2}
Длина rollout	T	2048 шагов

ТАБЛ. 1. Гиперпараметры PPO для теоретической постановки разд. VIII; конкретные значения подлежат уточнению на этапе экспериментальной проверки.

Функция вознаграждения. В соответствии с уравн. (31), общая структура награды:

$$r_t = -|t_t^{\text{render}} - t_t^{\text{perf}}| - \lambda \mathcal{L}_{\text{align}}(t) - \mu (a_t - a_{t-1})^2.$$

Гиперпараметры $\lambda \in [0.1, 1.0]$ и $\mu \in [0.05, 0.5]$ подбираются на валидации; стандартный приём — начать с малых μ и постепенно увеличивать его в течение обучения, обеспечивая «smooth ramp» от агрессивных тренировок без штрафа гладкости к финальному режиму с полным штрафом.

Связь с двухстадийной схемой ReaLchords. Схема ReaLchords [?] использует офлайнного учителя, видящего всю мелодию целиком, и KL-контроль к нему по уравнению (29). По аналогии в нашем контексте можно представить себе *офлайнного темпо-предсказателя*, имеющего доступ ко всему фрагменту исполнения целиком и оптимально подбирающего темповую траекторию. Тогда онлайнный агент дообучается с дополнительной KL-регуляризацией к этому учителю; такое расширение является потенциально плодотворным методологическим заимствованием и обозначено как направление продолжения работы в разд. IX.